



Escuela de Administración de Tecnologías de Información

Inteligencia de Negocios

Prueba corta #3

Diseño e implementación de una solución de Inteligencia de Negocios

Elaborado por:

Felipe Corrales Vargas

Jimena Rivera Madrigal

Fabián Martínez Camacho

Prof. Michael Lizandro

I Semestre, 2026

Tabla de contenidos

Stack técnico	3
Definición del reto técnico.....	3
ETL sin uso de IA generativa	4
Perfilamiento inicial.....	4
Reglas aplicadas.....	5
ETL con uso de IA generativa	5
Perfilamiento inicial.....	5
Reglas aplicadas.....	6
Comparación técnica de soluciones	9
Conclusiones	10
Anexos	12
1. ETL sin uso de IA generativa	12
1.1. Almacenamiento intermedio en Google Cloud Storage	12
1.2. Transformaciones aplicadas.....	13
1.3. Evidencia de carga al cloud de BigQuery.....	14
2. ETL con uso de IA generativa	16
2.1. Almacenamiento intermedio en Google Cloud Storage	16
2.2. Base de datos cargada en BigQuery.....	16
2.3. Transformaciones aplicadas.....	17
2.4. Evidencia de carga al cloud de BigQuery.....	18
2.5. Prompts relevantes para la ejecución.....	20
3. Bitácora.....	22

Stack técnico

La prueba se fundamenta en un ecosistema de cloud computing, seleccionado para garantizar la escalabilidad y la integración nativa entre servicios. A continuación, se detalla el rol de cada componente dentro del ciclo de vida del dato.

Componente	Herramienta	Función dentro del ETL	Justificación
Extracción	Kaggle (CSV)	Fuente de datos inicial	Permite trabajar con un dataset real con problemas de calidad para aplicar ETL
Almacenamiento intermedio	Google Cloud Storage	Guardar datos limpios en una capa staging	Permite almacenar datos en la nube antes de su procesamiento final
Herramienta ETL	Google Cloud Data Fusion	Diseño y ejecución del pipeline ETL	Ofrece una interfaz visual para construir procesos de integración de datos
Carga final / Data Warehouse	BigQuery	Almacenamiento final para análisis	Permite consultar grandes volúmenes de datos de forma rápida usando SQL

El flujo comienza con la carga de archivos planos desde Kaggle hacia un Bucket de Cloud Storage. Desde ahí, Data Fusion extrae los archivos, aplica reglas de limpieza y, finalmente, inserta los registros procesados en tablas de BigQuery, donde quedan disponibles para el consumo de business intelligence.

Definición del reto técnico

El reto principal radica en la adopción e implementación de Google Cloud Data Fusion, una tecnología de integración de datos de nivel empresarial cuya curva de aprendizaje representa el eje central de este desafío.

Este reto se desglosa en cuatro pilares críticos:

- Aprender a diseñar pipelines ETL en un entorno visual
- Configurar correctamente la conexión entre Google Cloud Storage y BigQuery
- Comprender cómo aplicar transformaciones dentro de la herramienta
- Manejar la ejecución y monitoreo de los datos

El stack seleccionado permite cubrir todas las etapas del proceso ETL (extracción, transformación, almacenamiento y carga), utilizando herramientas del ecosistema de Google Cloud Platform, lo que facilita la integración entre servicios y mejora la escalabilidad del sistema.

ETL sin uso de IA generativa

En la etapa inicial, se abordó el tratamiento de los datos de forma manual para comprender a fondo sus deficiencias técnicas y estructurales. A continuación, se presentan los hallazgos del perfilamiento y las reglas de transformación diseñadas para garantizar la integridad de la información en el ambiente Cloud.

Perfilamiento inicial

Para iniciar el proceso ETL, se realizó una exploración básica del dataset con el objetivo de entender su estructura y detectar posibles problemas de calidad en los datos.

#	Columna	Tipo de problema	Descripción del hallazgo
1	Transaction Date	Tipo de dato incorrecto	La fecha está almacenada como texto y no como tipo fecha
2	Discount Applied	Valores nulos	Se encontraron muchos valores vacíos, no se sabe si tiene o no descuento
3	Item	Valores nulos	Existen registros donde no dice el nombre del producto
4	Price Per Unit	Valores nulos	En algunos casos falta el precio por unidad.
5	Item / Price / Quantity / Total	Registros incompletos	Se detectaron filas donde todos estos campos están vacíos.
6	Transaction ID	Posible inconsistencia	Los ID no siguen un patrón específico ni de secuencia
7	Customer ID	Posible inconsistencia	Parecen ser muy poquitos clientes, para tantas transacciones
8	Item	Posible inconsistencia	Los ítems no tienen nombres significativos, podrían dificultar el análisis
9	Price Per Unit	Posible inconsistencia	Algunos precios podrían parecer bajos y otros altos para según el ítem que dice
10	Total Spent	Validar	Se necesita validar el precio gastado si esta correctamente calculo o con inconsistencias

Reglas aplicadas

A partir de los problemas identificados en el perfilamiento, se definieron reglas básicas de limpieza para mejorar la calidad de los datos.

#	Columna	Regla aplicada	Descripción
1	Transaction Date	Convertir tipo de dato	Se transformó la columna a formato de fecha estándar
2	Transaction	Validar duplicados	Validar si hay transacciones duplicadas y eliminarlas
3	Customer ID	Validar formato	Validar si todos los clientes tienen el mismo formato CUST_**
4	Item	Limpieza de datos	Verificar los espacios vacíos y rellenarlos con "Desconocidos"
5	Price / Quantity / Total	Limpieza de datos	Verificar los espacios vacíos y rellenarlos con "Null"
6	Discount Applied	Limpieza de datos	Verificar los espacios vacíos y rellenarlos con "Desconocidos"

ETL con uso de IA generativa

En esta segunda fase, se optimizó el flujo de trabajo integrando herramientas de IA generativa para agilizar la codificación y la resolución de errores complejos. El enfoque principal fue evaluar cómo la IA facilita la implementación de las reglas de transformación y la carga eficiente de los datos al entorno Cloud.

Perfilamiento inicial

El perfilamiento del dataset se realizó con apoyo de herramientas de IA generativa para identificar problemas de calidad de datos.

#	Columna	Tipo de problema	Descripción del hallazgo	Severidad
1	Discount Applied	Valores nulos	4,199 filas sin valor (33.4% del dataset). No se puede determinar si es "sin descuento" o dato no capturado	Alta
2	Item / Price / Quantity / Total	Valores nulos	604 filas con los 4 campos simultáneamente vacíos. Transacciones fantasmas con cabecera, pero sin detalle de producto	Alta
3	Price Per Unit	Valores nulos	609 filas sin precio, pero con Quantity y Total Spent presentes. Precio calculable pero no registrado	Alta
4	Item	Valores nulos	1,213 filas sin nombre de ítem (incluye los dos grupos anteriores)	Media
5	Transaction Date	Tipo de dato incorrecto	Columna de fechas almacenada como string/object. Impide operaciones temporales sin conversión previa	Media

#	Columna	Tipo de problema	Descripción del hallazgo	Severidad
6	Discount Applied	Tipo de dato incorrecto	Operaciones booleanas directas fallan silenciosamente	Media
7	Price Per Unit	Registro sospechoso	Solo 25 valores únicos con paso fijo de \$1.50 (de \$5.00 a \$41.00). Granularidad artificial impropia de un retail real	Media
8	Customer ID	Columna ambigua	Solo 25 clientes únicos para 12,575 transacciones (~500 por cliente). Imposibilita análisis de segmentación o comportamiento individual	Baja
9	Item	Columna ambigua	Nombres de ítems en formato código interno (Item_N_ABREV), sin nombres reales de producto. Impide análisis semántico de catálogo	Baja
10	Total Spent	Registro sospechoso	En 609 filas el total existe, pero el precio no, por lo que no puede auditarse si el descuento fue aplicado correctamente	Baja

Reglas aplicadas

A partir de los problemas identificados en el perfilamiento, se definieron reglas básicas de limpieza para mejorar la calidad de los datos apoyado del uso de la IA generativa.

#	Regla de negocio	Comando de data fusion	Explicación técnica	Severidad
1	Fecha estándar	parse-as-date :Transaction_Date yyyy-MM-dd	Convierte strings de fecha a un tipo Date reconocido por BigQuery, normalizando el formato.	Media
2	Descuento	set-column :Discount_Applied (empty(Discount_Applied)) ? 'Desconocido' : Discount_Applied	Maneja la integridad de datos reemplazando valores nulos o vacíos por una etiqueta por defecto.	Alta

#	Regla de negocio	Comando de data fusion	Explicación técnica	Severidad
3	Registros incompletos	set-column :Estado_Registro (Item == 'Item desconocido' Check_Total == 'Error Cálculo') ? 'Incompleto' : 'Validado'	Etiqueta las filas que fallaron en otras validaciones para una revisión manual posterior.	Alta
4	Cálculo de precio	set-column :Price_Per_Unit (Price_Per_Unit == 0.0 && Quantity > 0.0) ? (Total_Spent / Quantity) : Price_Per_Unit	Si el precio viene en cero pero hay total y cantidad, el sistema lo calcula solo.	Media
5	Ítem desconocido	set-column :Item (empty(Item)) ? 'Item desconocido' : Item	Asegura que no existan celdas vacías en la descripción del producto, manteniendo la consistencia.	Media
6	Validar transacción	set-column :Transaction_ID (Transaction_ID.startsWith('TXN_')) ? Transaction_ID : ('INV_' + Transaction_ID)	Valida el patrón del ID. Si no cumple, le añade el prefijo "INV_" (Invalid) para alertar al analista.	Baja
7	Validar cliente	set-column :Customer_ID (Customer_ID.startsWith('CUST_')) ? Customer_ID : ('INV_' + Customer_ID)	Aplica la misma lógica de patrones al ID del cliente para asegurar la trazabilidad.	Baja
8	Precios atípicos	set-column :Alerta_Precio (Price_Per_Unit > 500.0) ? 'Caro' : 'Normal'	Identifica automáticamente productos con precios fuera de lo común.	Baja
9	Rango cantidad	set-column :Alerta_Qty (Quantity < 1.0 Quantity > 10.0) ? 'Fuera de Rango' : 'OK'	Control de entrada de datos: valida que la cantidad comprada sea razonable (entre 1 y 10).	Baja

#	Regla de negocio	Comando de data fusion	Explicación técnica	Severidad
10	Integridad total	set-column :diff (Total_Spent - (Price_Per_Unit * Quantity)) set-column :Check_Total (diff != 0) ? 'Error Cálculo' : 'OK'	Calcula la diferencia y marca cualquier discrepancia distinta a cero como error.	Media

Comparación técnica de soluciones

A continuación, se presenta un contraste técnico entre la metodología tradicional y la asistida por inteligencia artificial generativa para el proceso ETL.

Categoría	Implementación 1 (Manual)	Implementación 2 (IA generativa)	Observaciones
Optimización del tiempo	Requirió una inversión extensiva en la escritura manual de scripts y lógica de transformación.	Reducción significativa del tiempo en generación de SQL y depuración de errores de esquema.	La mayor ganancia se observó en la carga final a BigQuery y el troubleshooting de IAM (Permisos de la nube).
Curva de aprendizaje	Proceso de prueba y error que permitió comprender a fondo la estructura del dataset.	Aplicación de conocimiento previo para supervisar los resultados de la IA con criterio técnico.	Realizar primero la fase manual evitó aceptar sugerencias de la IA ciegamente.
Calidad y precisión	Alta precisión debido al control total, pero con mayor riesgo de errores de sintaxis humanos.	Alta velocidad de escritura, aunque con puntos de "fricción" en lógica de perfilamiento inicial.	La intervención humana validó que las reglas de limpieza no eliminaran datos esenciales.
Manejo de stack técnico	Basado en la lectura de documentación oficial y configuración manual de GCP.	La IA actuó como mentor técnico, facilitando la configuración de ambientes Cloud complejos.	Agilizó la resolución de errores de aprovisionamiento en clústeres de Dataproc (permisos asociados para permitir la carga a la nube).
Reproducibilidad	Dependiente de la documentación manual de cada paso y script guardado.	Flujo más automatizado y fácil de replicar mediante el historial de prompts.	Ambas lograron el objetivo funcional, pero la IA facilitó la trazabilidad del proceso.

Conclusiones

El desarrollo de esta prueba corta permitió determinar que la inteligencia artificial generativa no actúa como un sustituto del conocimiento técnico, sino como un catalizador de la eficiencia del ingeniero. Al haber ejecutado inicialmente una implementación manual, se garantizó que la supervisión de los resultados de la IA se realizara con un criterio sólido, permitiendo identificar y corregir sugerencias que aunque sintácticamente correctas, no se alineaban perfectamente con las reglas de negocio o la estructura específica del dataset en BigQuery.

Asimismo, se concluye que la integración de herramientas de IA en el flujo de trabajo de Google Cloud Platform reduce drásticamente las barreras de configuración en entornos complejos. El uso de prompts especializados facilitó la resolución ágil de errores críticos de aprovisionamiento en Dataproc y la gestión de permisos en IAM, tareas que tradicionalmente consumen una parte considerable del tiempo de desarrollo debido a la densidad de la documentación técnica. Esto permitió que el esfuerzo se centrara en la calidad de la transformación de los datos y en la arquitectura del pipeline, logrando un proceso de carga final robusto y validado.

Referencias bibliográficas

- Aissi, S., Gouider, M. S., Sboui, T., y Ben Said, L. (2015). Personalized recommendation of SOLAP queries: theoretical framework and experimental evaluation. En *Proceedings of the 30th Annual ACM Symposium on Applied Computing* (pp. 1008–1014). Association for Computing Machinery. <https://doi.org/10.1145/2695664.2695826>
- Haridass, T., y Brown, E. (2017). *Learning Google BigQuery: A beginner's guide to mining massive datasets through interactive analysis*. Packt Publishing.
- Laaksonen, A., Korpimies, K., y Luukkainen, M. (2025). Trends in Students' SQL Queries in the Era of Generative AI. En *Proceedings of the 25th Koli Calling International Conference on Computing Education Research* (Art. 48, pp. 1–7). Association for Computing Machinery. <https://doi.org/10.1145/3769994.3770024>
- Thakurratan, R. S. (2018). *Google Cloud Platform Administration: Design highly available, scalable, and secure cloud solutions on GCP*. Packt Publishing.
- Zarate, G., Lopez Osa, M. J., Torre-Bastida, A. I., Iturraspe, U., Arjona, J., Navarro, B., y Gimeno, A. (2024). Evolution of Extract-Transform-Load (ETL) processes towards data product pipelines. En *Proceedings of the 4th Eclipse Security, AI, Architecture and Modelling Conference on Data Space* (pp. 25–32). Association for Computing Machinery. <https://doi.org/10.1145/3685651.3686662>

Anexos

1. ETL sin uso de IA generativa

En la siguiente subsección de anexos, se presentan las evidencias del proceso ETL realizado sin intervención de la inteligencia artificial generativa.

1.1. Almacenamiento intermedio en Google Cloud Storage

Los datos fueron almacenados inicialmente en Google Cloud Storage como etapa de almacenamiento intermedio, permitiendo su posterior procesamiento mediante el pipeline ETL.




Figura 1. Google Cloud Share -Iteración 1

1.2. Transformaciones aplicadas

Se aplicaron transformaciones orientadas a la limpieza y calidad de datos, incluyendo eliminación de espacios, tratamiento de valores nulos, conversión de tipos de datos y validaciones de consistencia.

Cloud Data Fusion | Studio OPERATIONS HUB SYSTEM ADMIN Basic Edition

Wrangler Properties 4.11.1
Wrangler - A interactive tool for data cleansing and transformation.

Green No errors found. Validate

Properties Documentation

Input Schema

Field	Type	Actions
Transaction_ID	string	+
Customer_ID	string	+
Category	string	+
Item	string	+
Price_Per_Unit	string	+
Quantity	string	+
Total_Spent	string	+
Payment_Method	string	+
Location	string	+
Transaction_Date	string	+
Discount_Applied	boolean	+

Input Selection and Prefilters

Label: Wrangler

Input field name: *

Precondition Language: ☒ JEXL ☐ SQL

Precondition (JEXL): false

Directives

Recipe:

```

2 fill-null-or-empty :Item 'Desconocido'
3 fill-null-or-empty :Price_Per_Unit 'Null'
4 fill-null-or-empty :Quantity 'Null'
5 fill-null-or-empty :Total_Spent 'Null'
6 fill-null-or-empty :Discount_Applied 'Desconocido'
7 filter-rows-on regex-not-match Customer_ID ^CUST_*
```

WRANGLE

Output Schema

Field	Type	Actions
Transaction_ID	string	+
Customer_ID	string	+
Category	string	+
Item	string	+
Price_Per_Unit	string	+
Quantity	string	+
Total_Spent	string	+
Payment_Method	string	+
Location	string	+
Transaction_Date	timestamp	+
Discount_Applied	boolean	+

Figura 2. Transformaciones aplicadas - Iteración 1

Cloud Data Fusion | Studio OPERATIONS HUB SYSTEM ADMIN Basic Edition

Wrangle

Cloud Storage Default - df-8408774366117636096-gg3rqcdm7d6622up5k... retail_store_sales.csv Columns: 11 | Rows: 1000

	String	String	String	String	String	String	String	String	String	String
	Transaction_ID	Customer_ID	Category	Item	Price_Per_Unit	Quantity	Total_Spent	Payment_Method		
1	TXN_6867343	CUST_09	Patisserie	Item_10_PAT	18.5	10.0	185.0	Digital Wallet		
2	TXN_3731986	CUST_22	Milk Products	Item_17_MILK	29.0	9.0	261.0	Digital Wallet		
3	TXN_9303719	CUST_02	Butchers	Item_12_BUT	21.5	2.0	43.0	Credit Card		
4	TXN_9458126	CUST_06	Beverages	Item_16_BEV	27.5	9.0	247.5	Credit Card		
5	TXN_4575373	CUST_05	Food	Item_6_FOOD	12.5	7.0	87.5	Digital Wallet		
6	TXN_7482416	CUST_09	Patisserie	Desconocido	Null	10.0	200.0	Credit Card		
7	TXN_3652209	CUST_07	Food	Item_1_FOOD	5.0	8.0	40.0	Credit Card		
8	TXN_1372952	CUST_21	Furniture	Desconocido	33.5	Null	Null	Digital Wallet		
9	TXN_9728486	CUST_23	Furniture	Item_16_FUR	27.5	1.0	27.5	Credit Card		
10	TXN_2722661	CUST_25	Butchers	Item_22_BUT	36.5	3.0	109.5	Cash		
11	TXN_8776416	CUST_22	Butchers	Item_3_BUT	8.0	9.0	72.0	Cash		
12	TXN_5422631	CUST_09	Milk Products	Desconocido	Null	8.0	52.0	Digital Wallet		
13	TXN_5874772	CUST_23	Food	Item_2_FOOD	6.5	7.0	45.5	Cash		
14	TXN_4413070	CUST_14	Patisserie	Item_24_PAT	39.5	6.0	237.0	Digital Wallet		
15	TXN_2490363	CUST_09	Milk Products	Item_16_MILK	27.5	2.0	55.0	Digital Wallet		

Transformation steps (7)

- 1 parse-as-simple-date :Transaction_Date yyyy-MM-dd
- 2 fill-null-or-empty :Item 'Desconocido'
- 3 fill-null-or-empty :Price_Per_Unit 'Null'
- 4 fill-null-or-empty :Quantity 'Null'
- 5 fill-null-or-empty :Total_Spent 'Null'
- 6 fill-null-or-empty :Discount_Applied 'Desconocido'
- 7 filter-rows-on regex-not-match Customer_ID ^CUST_*

Figura 3. Transformaciones aplicadas - Iteración 1

1.3. Evidencia de carga al cloud de BigQuery

Finalmente, los datos transformados fueron cargados en BigQuery, donde se validó la correcta inserción mediante consultas de verificación.




Figura 4. Carga al BigQuery

Field	Type	Include	Exclude
Transaction_ID	string	☒	☐
Customer_ID	string	☒	☐
Category	string	☒	☐
Item	string	☒	☐
Price_Per_Unit	string	☒	☐
Quantity	string	☒	☐
Total_Spent	string	☒	☐
Payment_Method	string	☒	☐
Location	string	☒	☐
Transaction_Date	timestamp	☒	☐
Discount_Applied	boolean	☒	☐

Figura 5. Carga al BigQuery




Figura 6. Errores encontrados

Cloud Data Fusion | Pipeline OPERATIONS HUB SYSTEM ADMIN Basic Edition

Pipeline execution failed. CLOSE

ETL-Retail No tags found. Click to add a new business tag.

Configure Schedule Stop Run Summary History Actions

Run 14 of 14 Runtime Args Logs Status Failed Start time 04-28-2026 08:05:27 PM Duration 6 secs Compute profile Autoscaling D...

SCROLL TO LATEST LOGS HIDE ADVANCED LOGS DOWNLOAD ALL

Time	Level	Message
04/28/2026 20:05:30	INFO	Creating Dataproc cluster cdap-etl-retail-e43e6049-436f-11f1-b9de-0af58758191d in project etl-retail-494716, in region us-west1, with image 2.3, with labels {goog-datafusion-instance=test, goog-datafusion-version=6_11, cdap-version=6_11_3-snapshot-1772644462818, goog-datafusion-edition=basic, goog-datafusion-project=etl-retail-494716}, endpoint dataproc.googleapis.com:443
04/28/2026 20:05:33	ERROR	'PROVISION' task failed in 'REQUESTING_CREATE' state for program run 'program_run:default.ETL-Retail.8c819951-4359-11f1-ab8d-0af58758191d.workflow.DataPipelineWorkflow.e43e6049-436f-11f1-b9de-0af58758191d' due to Dataproc operation failure: io.grpc.StatusRuntimeException: INVALID_ARGUMENT: User not authorized to act as service account '11897694863-compute@developer.gserviceaccount.com'. To act as a service account, user must have one of [Owner, Editor, Service Account User] roles. See https://cloud.google.com/iam/docs/understanding-service-accounts for additional details. Caused by: io.grpc.StatusRuntimeException: INVALID_ARGUMENT: User not authorized to act as service account '11897694863-compute@developer.gserviceaccount.com'. To act as a service account, user must have one of [Owner, Editor, Service Account User] roles. See https://cloud.google.com/iam/docs/understanding-service-accounts for additional details. Caused by: INVALID_ARGUMENT: User not authorized to act as service account '11897694863-compute@developer.gserviceaccount.com'. To act as a service account, user must have one of [Owner, Editor, Service Account User] roles. See https://cloud.google.com/iam/docs/understanding-service-accounts for additional details..

Figura 7. Errores encontrados

2. ETL con uso de IA generativa

En la siguiente subsección de anexos, se presentan las evidencias del proceso ETL realizado con la intervención de la inteligencia artificial generativa.

2.1. Almacenamiento intermedio en Google Cloud Storage

Se muestra la creación y configuración del bucket pc3-ia en Google Cloud Storage. En la imagen se evidencia la carga exitosa del archivo fuente retail_store_sales.csv, cumpliendo con el requisito de ingesta en un entorno Cloud antes de su procesamiento final.




Figura 8. Almacenamiento - Iteración 2

2.2. Base de datos cargada en BigQuery

Evidencia de la tabla inicial retail_store_sales dentro del conjunto de datos pc3_IA en BigQuery. Se observa el esquema de la tabla con los tipos de datos correctamente asignados.




Figura 9. Base de datos

2.3. Transformaciones aplicadas

Se detalla el uso de Cloud Data Fusion y su herramienta Wrangler para ejecutar la limpieza de datos. En la imagen se observa el historial de pasos de transformación, donde se aplicaron las reglas de conversión de tipos de datos, manejo de valores nulos y normalización de columnas, asegurando que el dataset cumpla con el esquema definido antes de su procesamiento final.

The screenshot shows the Google Cloud Data Fusion console. At the top, there's a search bar and navigation links. Below, the 'Instances' section shows a table with columns: Instance Name, Action, Edition, Region, Zone, Version, Notifications, Encryption, and Last Updated. The 'retail_store_sales.csv' dataset is selected, and the 'Wrangler' interface is open. The 'Data' tab shows a preview of the data with 11 columns. The 'Transformation steps' panel on the right shows a list of transformations applied to the data, including 'trim', 'set-type', 'set-column', and 'fill-null-or-empty'.

Transaction_ID	Customer_ID	Category	Item	Price_Per_Unit	Quantity	Total_Spent	Payment_Method	Location
TXN_6867343	CUST_09	Patisserie	Item_10_PAT	18.5	10.0	185.0	Digital Wallet	Online
TXN_3731986	CUST_22	Milk Products	Item_17_MILK	29.0	9.0	261.0	Digital Wallet	Online
TXN_9303719	CUST_02	Butchers	Item_12_BUT	21.5	2.0	43.0	Credit Card	Online
TXN_9458126	CUST_06	Beverages	Item_16_BEV	27.5	9.0	247.5	Credit Card	Online
TXN_4575373	CUST_05	Food	Item_6_FOOD	12.5	7.0	87.5	Digital Wallet	Online
TXN_7482416	CUST_09	Patisserie			10.0	200.0	Credit Card	Online
TXN_3652209	CUST_07	Food	Item_1_FOOD	5.0	8.0	40.0	Credit Card	In-store
TXN_1372952	CUST_21	Furniture		33.5			Digital Wallet	In-store
TXN_9728486	CUST_23	Furniture	Item_16_FUR	27.5	1.0	27.5	Credit Card	In-store
TXN_2722661	CUST_25	Butchers	Item_22_BUT	36.5	3.0	109.5	Cash	Online
TXN_8776416	CUST_22	Butchers	Item_3_BUT	8.0	9.0	72.0	Cash	In-store
TXN_5422631	CUST_09	Milk Products			8.0	52.0	Digital Wallet	In-store
TXN_5874772	CUST_23	Food	Item_2_FOOD	6.5	7.0	45.5	Cash	Online
TXN_4413070	CUST_14	Patisserie	Item_24_PAT	39.5	6.0	237.0	Digital Wallet	In-store

Figura 10. Tabla sin transformar

The screenshot shows the Google Cloud Data Fusion console with the 'Wrangler' interface. The 'Data' tab shows a preview of the data with 14 columns. The 'Transformation steps' panel on the right shows a list of transformations applied to the data, including 'trim', 'set-type', 'set-column', 'fill-null-or-empty', and 'set-column'.

Transaction_ID	Customer_ID	Category	Item	Price_Per_Unit	Quantity	Total_Spent	Payment_Method	Location	Discount_Applied	Discount_Applied_2
TXN_6867343	CUST_09	Patisserie	Item_10_PAT	18.5	10.0	185.0	Digital Wallet	Online		
TXN_3731986	CUST_22	Milk Products	Item_17_MILK	29.0	9.0	261.0	Digital Wallet	Online		
TXN_9303719	CUST_02	Butchers	Item_12_BUT	21.5	2.0	43.0	Credit Card	Online		
TXN_9458126	CUST_06	Beverages	Item_16_BEV	27.5	9.0	247.5	Credit Card	Online		
TXN_4575373	CUST_05	Food	Item_6_FOOD	12.5	7.0	87.5	Digital Wallet	Online		
TXN_7482416	CUST_09	Patisserie	Item desconocido	0.0	10.0	200.0	Credit Card	Online		
TXN_3652209	CUST_07	Food	Item_1_FOOD	5.0	8.0	40.0	Credit Card	In-store		
TXN_1372952	CUST_21	Furniture	Item desconocido	33.5	0.0	0.0	Digital Wallet	In-store		
TXN_9728486	CUST_23	Furniture	Item_16_FUR	27.5	1.0	27.5	Credit Card	In-store		
TXN_2722661	CUST_25	Butchers	Item_22_BUT	36.5	3.0	109.5	Cash	Online		
TXN_8776416	CUST_22	Butchers	Item_3_BUT	8.0	9.0	72.0	Cash	In-store		
TXN_5422631	CUST_09	Milk Products	Item desconocido	0.0	8.0	52.0	Digital Wallet	In-store		
TXN_5874772	CUST_23	Food	Item_2_FOOD	6.5	7.0	45.5	Cash	Online		
TXN_4413070	CUST_14	Patisserie	Item_24_PAT	39.5	6.0	237.0	Digital Wallet	In-store		

Figura 11. Tabla transformada

2.4. Evidencia de carga al cloud de BigQuery

Esta captura muestra el diseño y la ejecución exitosa del pipeline de datos. El flujo conecta el origen en Google Cloud Storage con el nodo de transformación y, finalmente, con el sumidero de BigQuery. Se confirma que la carga fue satisfactoria mediante el estado de ejecución verde, validando la interoperabilidad de las herramientas del stack técnico seleccionado.




Figura 122. Carga al BigQuery




Figura 13. Carga al big query




Figura 144. Errores encontrados




Figura 155. Solución de errores

2.5.Prompts relevantes para la ejecución

Para lograr estos resultados, se usó una serie de instrucciones precisas que permitieron a la IA generar los scripts de limpieza y resolver los bloqueos técnicos del pipeline. A continuación, se comparten los prompts que fueron clave para automatizar las transformaciones y asegurar la carga exitosa en BigQuery.

Fase del proceso	Prompt
Perfilamiento de datos	Actúa como un experto en ingeniería de datos para un proyecto de Inteligencia de Negocios en el TEC. Necesito limpiar el dataset retail_store_sales.csv para un proceso ETL que terminará en BigQuery. El archivo original está 'sucio' y presenta múltiples problemas de calidad. Basado en mi perfilamiento previo, aplica estrictamente las siguientes reglas de transformación: Fechas: Convierte la columna Transaction Date de texto a un formato de fecha estándar YYYY-MM-DD, Manejo de Nulos: En las columnas Item y Discount Applied, rellena los vacíos con el texto 'Desconocido'. Para las columnas numéricas Price, Quantity y Total, rellena los nulos con 'Null' o 0 para mantener la integridad del cálculo, Normalización de IDs: Asegúrate de que los Customer ID sigan un formato consistente (CUST_) y elimina registros duplicados basados en el Transaction ID y Limpieza de Texto: Elimina espacios en blanco extra en todos los campos de texto. Por favor, dime cómo ejecutar estos pasos específicamente en la herramienta Wrangler de Cloud Data Fusion para que mi pipeline sea reproducible. El objetivo es que los datos lleguen limpios a la capa analítica en la nube.
Configuración de Stack	Actúa como arquitecto de soluciones en Google Cloud. Necesito configurar un entorno donde Cloud Data Fusion extraiga datos de Cloud Storage y los cargue en BigQuery. Explicame qué permisos de IAM son indispensables para que la cuenta de servicio de cómputo pueda crear un clúster de Dataproc eficientemente y cómo debo configurar el sink de BigQuery para que reconozca el esquema de mi dataset retail store sales.
Limpieza y transformación	Utilizando la herramienta Wrangler en Cloud Data Fusion, genera las reglas de transformación necesarias para limpiar mi dataset. Necesito los pasos exactos para: Cambiar el tipo de dato de 'String' a 'Integer/Float' en columnas de montos, aplicar una directiva de 'Fill Nulls' con valores personalizados, usar 'Parse as Date' para estandarizar el tiempo, dame las instrucciones en el formato que Wrangler acepta para copiarlas directamente en la consola de transformaciones.
Depuración de errores	Estoy recibiendo un error 400 Dataproc cluster create operation failed al intentar ejecutar mi pipeline. El mensaje indica que la cuenta de servicio ...compute@developer.gserviceaccount.com no tiene el rol de Dataproc Worker y que mi usuario no está autorizado para actuar como cuenta de servicio. ¿Cuáles son los comandos de gcloud o los pasos en la consola de IAM para corregir estos permisos y permitir que el pipeline pase de 'Provisioning' a 'Running'?"

retail_store_sales
ACSV

CSV

Actúa como un experto en ingeniería de datos para un proyecto de Inteligencia de Negocios en el TEC. Necesito limpiar el dataset `retail_store_sales.csv` para un proceso ETL que terminará en BigQuery. El archivo original está 'sucio' y presenta múltiples problemas de calidad.

Basado en mi perfilamiento previo, aplica estrictamente las siguientes reglas de transformación:

1. Fechas: Convierte la columna `Transaction Date` de texto a un formato de fecha estándar YYYY-MM-DD.
2. Manejo de Nulos: En las columnas `Item` y `Discount Applied`, rellena los vacíos con el texto 'Desconocido'. Para las columnas numéricas `Price`, `Quantity` y `Total`, rellena los nulos con 'Null' o 0 para mantener la integridad del cálculo.
3. Normalización de IDs: Asegúrate de que los `Customer ID` sigan un formato consistente (CUST_) y elimina registros duplicados basados en el `Transaction ID`.
4. Limpieza de Texto: Elimina espacios en blanco extra en todos los campos de texto.

Por favor, dime cómo ejecutar estos pasos específicamente en la herramienta Wrangler de Cloud Data Fusion para que mi pipeline sea reproducible. El objetivo es que los datos lleguen limpios a la capa analítica en la nube.

Mostrar menos

8:57 p.m. 🔄 📄

Se ejecutaron 6 comandos, archivo visualizado, archivo leído >

Aquí está el reporte completo del proceso ETL aplicado, junto con las instrucciones equivalentes para Cloud Data Fusion Wrangler.

✔ **Resultados del Profiling y Limpieza**

Columna	Problema encontrado	Regla aplicada	Resultado
<code>Transaction Date</code>	Ya estaba en YYYY-MM-DD, pero como string	<code>pd.to_datetime() + .strftime('%Y-%m-%d')</code>	✔ Tipo date validado
<code>Item</code>	1,213 nulos	<code>fillna('Desconocido')</code>	✔ 0 nulos
<code>Discount Applied</code>	4,199 nulos (campo bool/object)	<code>fillna('Desconocido')</code>	✔ 0 nulos
<code>Price Per Unit</code>	609 nulos	<code>fillna(0)</code>	✔ 0 nulos
<code>Quantity</code>	604 nulos	<code>fillna(0)</code>	✔ 0 nulos
<code>Total Spent</code>	604 nulos	<code>fillna(0)</code>	✔ 0 nulos
<code>Customer ID</code>	100% ya con formato CUST_XX	Normalización aplicada preventivamente	✔ Sin cambios necesarios
<code>Transaction ID</code>	Sin duplicados en 12,575 filas	<code>drop_duplicates()</code>	✔ 0 eliminados
Espacios en blanco	Revisados todos los campos de texto	<code>.str.strip()</code> en todas las columnas string	✔ Limpio

Figura 16. Evidencia del prompt inicial

3. Bitácora

Esta sección presenta el registro detallado de los tiempos invertidos en cada etapa del proyecto, permitiendo contrastar la eficiencia entre la ejecución manual y la asistida por inteligencia artificial.

Fase del proceso	Tiempo implementación 1 sin uso de IA generativa		Tiempo implementación 2 con uso de IA generativa		Diferencia
	Tiempo	Evidencia	Tiempo	Evidencia	
Perfilamiento de datos	20 minutos	Revisión manual del CSV + Tabla de perfilamiento inicial	5 minutos	Figura 16 + Análisis propio de la información	15 minutos menos
Configuración de Stack	35 minutos	Figura 1 + configuración manual GCP	9 minutos	Figura 8 y Figura 9	26 minutos menos
Limpieza y transformación	35 minutos	Figura 2 y Figura 3	19 minutos	Figura 10 y Figura 11	16 minutos menos
Depuración de errores	50 minutos	Figura 6 y figura 7	43 minutos	Figura 13 y Figura 15	7 minutos menos
Carga final	5 minutos	Figura 4 y figura 5	17 segundos	Figura 15	5 minutos y 43 segundos menos
Total	2 horas y 25 minutos	-	1 hora y 16 minutos	-	1 hora y 9 minutos menos